ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÁO CÁO GIỮA KỲ 2

ĐỀ TÀI 10: LOAN DEFAULT DATASET
PHÂN TÍCH RỦI RO VỠ NỢ KHOẢN VAY THẾ CHẤP

Giảng viên:	**Trần Đức Minh**	
Môn học:	**Khoa học dữ liệu trong kinh tế và kinh doanh**	
Lớp học phần:	**AEP.TOKT1138.LS(126)_01**	
Nhóm:	**Nhóm 2**	
Thành viên:	**Phạm Hùng Anh**	**11240220**
	Trần Thành Lộc	**11242555**
	Tạ Minh Quang	**11240798**
	Nguyễn Trọng Hoàn	**11248012**
	Vũ Huy Anh	**11246422**
Repository GitHub:	https://github.com/hunganh33333/loan-default-midterm2	

Hà Nội, 2026

MỤC LỤC

TÓM TẮT.....1
CHƯƠNG 1: GIỚI THIỆU.....2
1.1. Bối cảnh.....2
1.2. Mục tiêu.....2
1.3. Công cụ và mã nguồn.....2
1.4. Kết cấu báo cáo.....3
CHƯƠNG 2: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU.....4
2.1. Nguồn dữ liệu và mục tiêu bài toán.....4
2.2. Cấu trúc, kiểu dữ liệu và biến mục tiêu.....6
2.3. Tỷ lệ giá trị khuyết thiếu.....7
2.4. Tính nhất quán của dữ liệu.....7
CHƯƠNG 3: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU.....9
3.1. Giá trị sai định dạng và bất hợp lý.....9
3.2. Dữ liệu trùng lặp.....9
3.3. Giá trị thiếu không ngẫu nhiên và hiện tượng rò rỉ dữ liệu.....10
3.4. Ngoại lệ và độ lệch phân phối.....11
3.5. Giải trình lựa chọn kỹ thuật.....13
CHƯƠNG 4: PHÂN TÍCH, KIỂM ĐỊNH GIẢ THUYẾT VÀ TRỰC QUAN HÓA. .15
4.1. Giả thuyết và phương pháp kiểm định.....15
4.2. Giả thuyết H1 về điểm tín dụng.....16
4.3. Giả thuyết H2 về tỷ lệ khoản vay trên giá trị tài sản.....17
4.4. Giả thuyết H3 về tỷ lệ nợ trên thu nhập.....18
4.5. Giả thuyết H4 về thu nhập.....19
4.6. Giả thuyết H5 về nhóm tuổi.....20
4.7. Giả thuyết H6 về cấu trúc khoản vay.....21
4.8. Giả thuyết H7 về đơn vị chấm điểm tín dụng.....22
4.9. Kết hợp LTV với DTI và tương quan giữa các biến số.....23
4.10. Tổng hợp kết quả kiểm định.....25

4.11. Kiểm chứng bằng mô hình học máy.....25
CHƯƠNG 5: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ.....28
5.1. Các phát hiện nổi bật.....28
5.2. Đánh giá tác động của quy tắc sàng lọc.....28
5.3. Khuyến nghị.....29
5.4. Hạn chế của dữ liệu và hướng mở rộng.....30
KẾT LUẬN.....31
TÀI LIỆU THAM KHẢO.....32
PHỤ LỤC.....33
Phụ lục 1: Cấu trúc repository GitHub và cách chạy lại.....33

DANH MỤC BẢNG

Tên bảng	Trang
Bảng 1: Từ điển dữ liệu	4
Bảng 2: Các vấn đề về tính nhất quán của dữ liệu	7
Bảng 3: Rà soát giá trị bất hợp lý trong các cột số	9
Bảng 4: Bảng chéo giữa việc thiếu lãi suất và Status	10
Bảng 5: Phát hiện ngoại lệ bằng phương pháp IQR	11
Bảng 6: Các kỹ thuật tiền xử lý và lý do lựa chọn	13
Bảng 7: Tỷ lệ vỡ nợ theo nhóm LTV trước và sau khi điền median	14
Bảng 8: Kết quả kiểm định các giả thuyết	25
Bảng 9: Kết quả mô hình trên tập kiểm tra	26
Bảng 10: Mô phỏng tác động của quy tắc sàng lọc	28

DANH MỤC HÌNH

Tên hình	Trang
Hình 1: Phân bố biến mục tiêu Status	6
Hình 2: Tỷ lệ giá trị thiếu theo cột	7
Hình 3: Tỷ lệ vỡ nợ khi một cột bị thiếu và khi có dữ liệu	10
Hình 4: Phân phối các biến tiền tệ và phân phối thu nhập trước, sau khi lấy log	12
Hình 5: Tỷ lệ vỡ nợ theo nhóm điểm tín dụng và phân phối điểm tín dụng theo Status	16
Hình 6: Tỷ lệ vỡ nợ theo nhóm LTV	17
Hình 7: Tỷ lệ vỡ nợ theo nhóm DTI	18
Hình 8: Tỷ lệ vỡ nợ theo năm nhóm thu nhập	19
Hình 9: Tỷ lệ vỡ nợ theo nhóm tuổi	20
Hình 10: Tỷ lệ vỡ nợ khi có và không có từng đặc điểm cấu trúc khoản vay	21
Hình 11: Tỷ lệ vỡ nợ theo đơn vị chấm điểm tín dụng	22
Hình 12: Tỷ lệ vỡ nợ theo nhóm LTV và nhóm DTI	23
Hình 13: Ma trận tương quan Spearman giữa các biến số	24
Hình 14: Ma trận nhầm lẫn và mức độ quan trọng của thuộc tính trong mô hình Random Forest ở kịch bản B	26

DANH MỤC TỪ VIẾT TẮT

STT	Viết tắt	Tiếng Anh	Tiếng Việt
1	AUC	Area Under the ROC Curve	Diện tích dưới đường cong ROC
2	DTI	Debt to Income ratio	Tỷ lệ nợ trên thu nhập
3	EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu
4	IQR	Interquartile Range	Khoảng tứ phân vị
5	LR	Logistic Regression	Hồi quy Logistic
6	LTV	Loan to Value ratio	Tỷ lệ khoản vay trên giá trị tài sản
7	MNAR	Missing Not At Random	Thiếu không ngẫu nhiên
8	RF	Random Forest	Rừng ngẫu nhiên

TÓM TẮT

Báo cáo này phân tích bộ dữ liệu Loan Default Dataset gồm 148.670 khoản vay thế chấp phát sinh trong năm 2019 với 34 thuộc tính. Trong số đó có 36.639 khoản bị vỡ nợ, chiếm 24,64%. Nhóm thực hiện phân tích theo bốn giai đoạn gồm đánh giá dữ liệu ban đầu, làm sạch dữ liệu, kiểm định giả thuyết kết hợp trực quan hóa và cuối cùng là đánh giá tác động để đưa ra khuyến nghị. Toàn bộ mã nguồn được viết trong một notebook trên Google Colab và lưu trên GitHub của nhóm.

Phát hiện quan trọng nhất liên quan đến chất lượng dữ liệu. Các giá trị bị thiếu trong bộ dữ liệu không xuất hiện ngẫu nhiên mà gắn gần như tuyệt đối với vỡ nợ. Tất cả các khoản vay thiếu thông tin lãi suất đều là khoản vỡ nợ, trong khi 98.187 hồ sơ có đầy đủ thông tin thì không có khoản nào vỡ nợ. Vì vậy nếu đưa nguyên dữ liệu vào mô hình, độ chính xác sẽ đạt 100% nhưng kết quả này không dùng được trong thực tế. Sau khi loại các thuộc tính gây rò rỉ, mô hình Random Forest đạt AUC 0,771.

Về các yếu tố rủi ro, tỷ lệ vỡ nợ tăng mạnh khi khoản vay vượt giá trị tài sản, tức LTV trên 100%, với tỷ lệ vỡ nợ 65,1%, và khi tỷ lệ nợ trên thu nhập vượt 50% với tỷ lệ 42,7%. Cách thức trả nợ cũng ảnh hưởng lớn. Khoản vay trả gộp vào cuối kỳ có tỷ lệ vỡ nợ 77,7% và khoản vay trả gốc âm có tỷ lệ 44,6%, trong khi phần còn lại chỉ khoảng 23%. Ngược lại, điểm tín dụng trong bộ dữ liệu gần như không phân biệt được người vay rủi ro, tỷ lệ vỡ nợ ở mọi nhóm điểm chỉ dao động từ 24,3% đến 25,2%.

Nếu ngân hàng áp dụng ngưỡng LTV không quá 100%, DTI không quá 50% và kiểm soát hai hình thức trả nợ nói trên thì chỉ cần thẩm định kỹ 18% hồ sơ nhưng đã bao quát được 42,9% số khoản vỡ nợ. Ngoài ra nhóm đề xuất ngân hàng chuẩn hóa việc lưu dữ liệu tại thời điểm xét duyệt và không sử dụng giới tính trong quyết định cho vay.

CHƯƠNG 1: GIỚI THIỆU

1.1. Bối cảnh

Rủi ro tín dụng luôn là mối quan tâm hàng đầu của các ngân hàng. Với khoản vay thế chấp bất động sản, số tiền vay thường lớn và thời hạn kéo dài nhiều năm nên mỗi khoản vỡ nợ đều gây ra tổn thất đáng kể. Nếu xác định sớm được những đặc điểm của người vay và của khoản vay có liên quan đến vỡ nợ, ngân hàng có thể xây dựng tiêu chí xét duyệt hợp lý hơn, định giá khoản vay sát với rủi ro hơn và tập trung nguồn lực thẩm định vào những hồ sơ thật sự cần thiết.

1.2. Mục tiêu

Báo cáo hướng tới năm mục tiêu sau.

(1) Đánh giá cấu trúc và chất lượng của bộ dữ liệu Loan Default Dataset.
(2) Làm sạch dữ liệu và giải thích lý do lựa chọn từng kỹ thuật tiền xử lý.
(3) Kiểm định bảy giả thuyết về các yếu tố liên quan đến vỡ nợ bằng phương pháp thống kê và biểu đồ.
(4) Dùng mô hình phân loại có giám sát để kiểm chứng lại các phát hiện.
(5) Đề xuất giải pháp có thể áp dụng trong thực tế và chỉ ra những hạn chế của dữ liệu.

1.3. Công cụ và mã nguồn

Nhóm sử dụng Python 3 trên Google Colab cùng các thư viện pandas, NumPy, SciPy, scikit-learn, Matplotlib và Seaborn. Toàn bộ quá trình xử lý nằm trong notebook Loan_Default_Analysis.ipynb, có chú thích cho từng khối lệnh và chạy được liên tục từ đầu đến cuối bằng lệnh Run all. Mã nguồn và báo cáo được lưu tại địa chỉ https://github.com/hunganh33333/loan-default-midterm2.

Trong phần văn bản, số thập phân được viết bằng dấu phẩy theo cách viết tiếng Việt. Riêng các con số in trên hình được giữ nguyên dấu chấm theo mặc định của Python.

1.4. Kết cấu báo cáo

Ngoài phần giới thiệu, báo cáo gồm bốn chương tương ứng với bốn giai đoạn của đề bài. Chương 2 trình bày việc thu thập và đánh giá dữ liệu ban đầu. Chương 3 là tiền xử lý và làm sạch dữ liệu. Chương 4 là phân tích, kiểm định giả thuyết và trực quan hóa. Chương 5 là đánh giá tác động và khuyến nghị.

CHƯƠNG 2: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

2.1. Nguồn dữ liệu và mục tiêu bài toán

Nhóm sử dụng bộ dữ liệu Loan Default Dataset do tác giả Yasser H. đăng tải trên Kaggle. Dữ liệu chỉ gồm một file Loan_Default.csv dung lượng 28,3 MB với 148.670 dòng và 34 cột. Mỗi dòng là một khoản vay thế chấp phát sinh trong năm 2019. Biến mục tiêu là Status, nhận giá trị 1 nếu khoản vay bị vỡ nợ và 0 nếu không. Đây là bài toán phân loại nhị phân, trong đó nhóm muốn tìm hiểu những đặc điểm nào gắn với khả năng vỡ nợ và có thể dự báo vỡ nợ từ thông tin hồ sơ ở mức độ nào.

Trong notebook, dữ liệu được nạp lần lượt từ file trên máy, từ Kaggle thông qua thư viện kagglehub và cuối cùng là từ bản sao trên GitHub. Cách làm này giúp lệnh Run all chạy được mà không cần đăng nhập Kaggle.

Tác giả bộ dữ liệu không công bố từ điển dữ liệu, nhiều thuộc tính lại được mã hóa dưới dạng type1, p1, l1 nên không rõ ý nghĩa. Cột diễn giải trong Bảng 1 là cách hiểu của nhóm dựa trên tên biến và các khái niệm thường gặp trong cho vay thế chấp, vì vậy chỉ nên xem đây là giả định.

Bảng 1: Từ điển dữ liệu

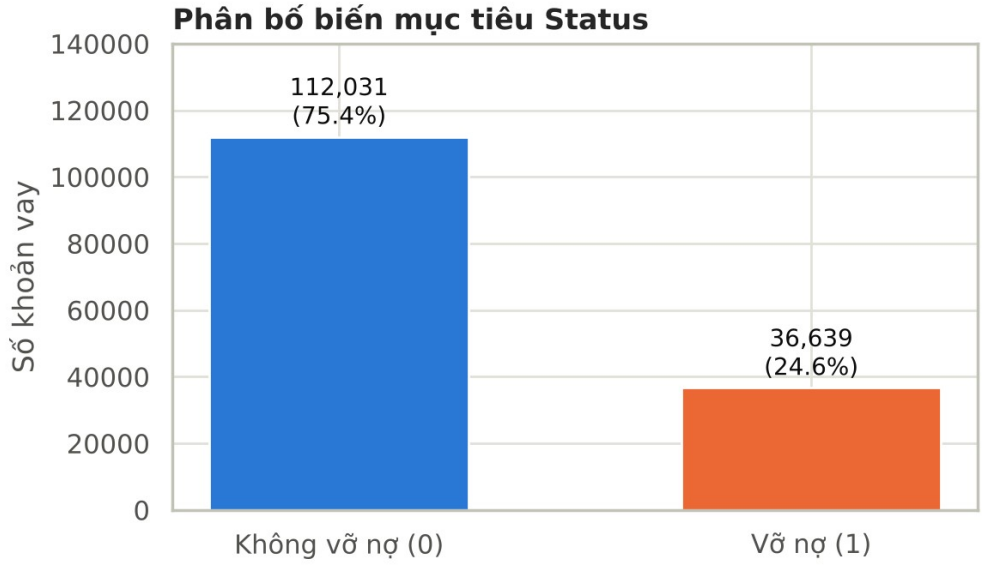
Thuộc tính	Kiểu	Diễn giải (giả định)	Giá trị	% thiếu
ID	Số	Mã khoản vay	148.670 giá trị	0
year	Số	Năm phát sinh khoản vay	Chỉ có 2019	0
loan_limit	Phân loại	Trong hạn mức chuẩn (cf) hoặc vượt hạn mức (ncf)	cf, ncf	2,25
Gender	Phân loại	Giới tính người vay	Male, Female, Joint, Sex Not Available	0
approv_in_adv	Phân loại	Được phê duyệt trước	pre, nopre	0,61
loan_type	Phân loại	Loại khoản vay	type1, type2, type3	0
loan_purpose	Phân loại	Mục đích vay	p1, p2, p3, p4	0,09
Credit_Worthiness	Phân loại	Mức tín nhiệm	l1, l2	0
open_credit	Phân loại	Có hạn mức tín dụng mở	opc, nopc	0
business_or_commercial	Phân loại	Vay cho mục đích kinh doanh	b/c, nob/c	0
loan_amount	Số	Số tiền vay	16.500 đến 3.576.500	0

Thuộc tính	Kiểu	Diễn giải (giả định)	Giá trị	% thiếu
rate_of_interest	Số	Lãi suất (%/năm)	0 đến 8	24,51
Interest_rate_spread	Số	Chênh lệch lãi suất so với lãi suất tham chiếu	âm 3,64 đến 3,36	24,64
Upfront_charges	Số	Phí trả trước	0 đến 60.000	26,66
term	Số	Kỳ hạn (tháng)	96 đến 360	0,03
Neg_ammortization	Phân loại	Trả gốc âm, dư nợ tăng dần	neg_amm, not_neg	0,08
interest_only	Phân loại	Có thời gian chỉ trả lãi	int_only, not_int	0
lump_sum_payment	Phân loại	Trả gộp một khoản lớn vào cuối kỳ	lpsm, not_lpsm	0
property_value	Số	Giá trị tài sản thế chấp	8.000 đến 16.508.000	10,16
construction_type	Phân loại	Nhà xây tại chỗ (sb) hoặc nhà lắp ghép (mh)	sb, mh	0
occupancy_type	Phân loại	Nhà ở chính (pr), nhà thứ hai (sr) hoặc nhà đầu tư (ir)	pr, sr, ir	0
Secured_by	Phân loại	Tài sản bảo đảm	home, land	0
total_units	Phân loại	Số căn hộ của tài sản	1U đến 4U	0
income	Số	Thu nhập người vay	0 đến 578.580	6,15
credit_type	Phân loại	Đơn vị chấm điểm tín dụng	CIB, CRIF, EXP, EQUI	0
Credit_Score	Số	Điểm tín dụng	500 đến 900	0
co-applicant_credit_type	Phân loại	Đơn vị chấm điểm của người đồng vay	CIB, EXP	0
age	Phân loại	Nhóm tuổi	7 nhóm, từ dưới 25 đến trên 74	0,13
submission_of_application	Phân loại	Nộp hồ sơ trực tiếp cho tổ chức hay không	to_inst, not_inst	0,13
LTV	Số	Tỷ lệ khoản vay trên giá trị tài sản (%)	0,97 đến 7.831	10,16
Region	Phân loại	Vùng	North, south, central, North-East	0
Security_Type	Phân loại	Hình thức bảo đảm	direct, Indriect	0
Status	Số	Biến mục tiêu, 1 là vỡ nợ	0, 1	0
dtir1	Số	Tỷ lệ nợ trên thu nhập, DTI (%)	5 đến 61	16,22

Nguồn: Nhóm tác giả tổng hợp từ Loan Default Dataset (Kaggle)

2.2. Cấu trúc, kiểu dữ liệu và biến mục tiêu

Dữ liệu có 13 cột dạng số và 21 cột dạng phân loại. Hai cột age và total_units về bản chất là số có thứ tự nhưng lại được lưu dưới dạng chuỗi, nhóm tuổi được ghi theo khoảng tuổi còn số căn hộ được ghi kèm chữ U như 1U, 2U. Cột term lưu kỳ hạn theo tháng nhưng có kiểu số thực dù giá trị luôn là số nguyên.

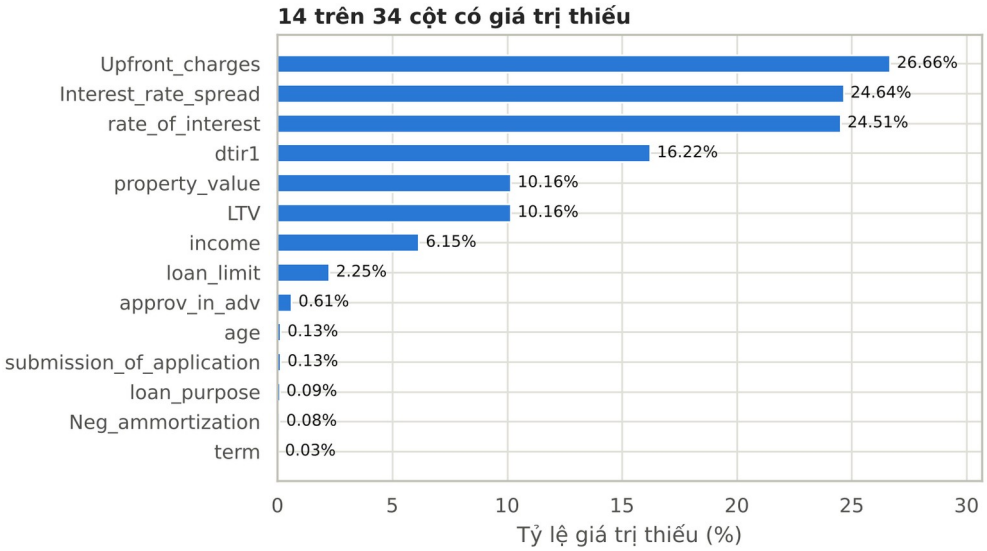


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 1: Phân bố biến mục tiêu Status

Hình 1 cho thấy có 112.031 khoản không vỡ nợ, chiếm 75,36%, và 36.639 khoản vỡ nợ, chiếm 24,64%. Như vậy cứ khoảng ba khoản vay tốt thì có một khoản vỡ nợ. Dữ liệu mất cân bằng ở mức nhẹ nên nếu chỉ nhìn vào độ chính xác (Accuracy) thì dễ bị đánh lừa, vì một mô hình luôn dự đoán không vỡ nợ cũng đúng tới 75%. Do đó nhóm đánh giá mô hình bằng AUC, Recall, Precision và F1, đồng thời chia tập huấn luyện và tập kiểm tra theo phân tầng để cả hai tập đều giữ tỷ lệ vỡ nợ 24,6%.

2.3. Tỷ lệ giá trị khuyết thiếu



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 2: Tỷ lệ giá trị thiếu theo cột

Có 14 trên 34 cột bị thiếu dữ liệu. Bốn cột thiếu nhiều nhất là Upfront_charges với 26,66%, Interest_rate_spread với 24,64%, rate_of_interest với 24,51% và dtir1 với 16,22%. Hai cột property_value và LTV cùng thiếu 10,16%, các cột còn lại thiếu dưới 6,2%. Nhóm để ý thấy tỷ lệ thiếu của Interest_rate_spread đúng bằng tỷ lệ vỡ nợ là 24,64%. Sự trùng khớp này khiến nhóm nghi ngờ dữ liệu thiếu có liên quan đến biến mục tiêu, và điều này được kiểm tra kỹ hơn ở mục 3.3.

2.4. Tính nhất quán của dữ liệu

Vì bộ dữ liệu chỉ có một file nên nhóm không phải ghép bảng qua khóa chính và khóa ngoại. Cột ID gồm 148.670 giá trị không trùng nhau và không có dòng nào bị lặp lại hoàn toàn. Tuy vậy, khi so sánh các cột với nhau, nhóm phát hiện một số vấn đề về tính nhất quán được tổng hợp trong Bảng 2.

Bảng 2: Các vấn đề về tính nhất quán của dữ liệu

Vấn đề	Bằng chứng	Hướng xử lý
Cột hằng số	Cột year chỉ có một giá trị là 2019	Bỏ cột

Vấn đề	Bằng chứng	Hướng xử lý
Ba cột trùng thông tin	33 dòng có construction_type là mh cũng chính là 33 dòng có Secured_by là land và Security_Type là Indriect, tất cả đều vỡ nợ	Giữ construction_type, bỏ hai cột còn lại
Hai cột trùng thông tin	business_or_commercial bằng b/c đúng ở 20.762 dòng có loan_type là type2	Bỏ business_or_commercial
Cột được tính từ cột khác	LTV bằng loan_amount chia property_value nhân 100, sai số lớn nhất chỉ $4{,}9\times10^{-8}$	Giữ lại nhưng lưu ý đa cộng tuyến
Thiếu cùng lúc	property_value và LTV thiếu ở cùng các dòng; age và submission_of_application cùng thiếu ở 200 dòng	Xử lý theo cặp
Nhãn không thống nhất	Trong Region, North và North-East viết hoa còn south và central viết thường; Indriect bị sai chính tả	Chuẩn hóa nhãn
Nhãn mang nghĩa thiếu	Gender có 37.659 dòng ghi Sex Not Available	Giữ thành nhóm riêng là Không rõ

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

CHƯƠNG 3: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

3.1. Giá trị sai định dạng và bất hợp lý

Bảng 3: Rà soát giá trị bất hợp lý trong các cột số

Kiểm tra	Số dòng	Tỷ lệ vỡ nợ	Đánh giá
Thu nhập bằng 0	1.260	99,4%	Không hợp lý với người vay thế chấp nên coi là thiếu
LTV trên 100%, tức vay nhiều hơn giá trị tài sản	1.799	65,1%	Có thể xảy ra trong thực tế nhưng rủi ro cao, giữ lại
LTV trên 200%, cao nhất 7.831%	17	64,7%	Không hợp lý, cắt về phân vị 99%
Lãi suất bằng 0	1	0%	Chỉ có một trường hợp, giữ lại
Kỳ hạn lẻ, khác 180, 240, 300 và 360 tháng	5.282	22,7%	Hợp lệ, giữ lại
Chênh lệch lãi suất âm	21.883	0,0%	Hợp lệ vì lãi suất có thể thấp hơn mức tham chiếu, giữ lại

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

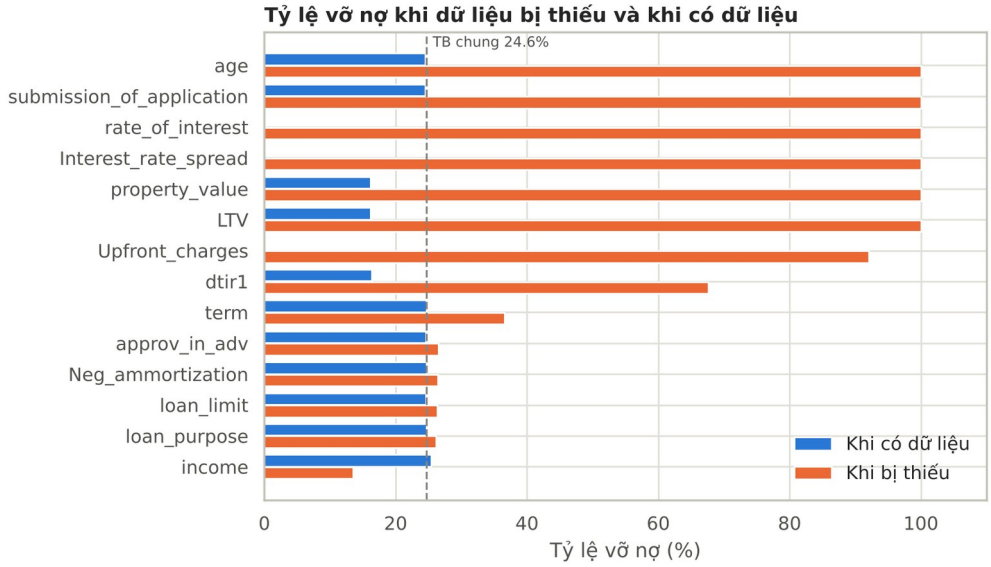
Điểm đáng lo nhất là 1.260 hồ sơ có thu nhập bằng 0 nhưng tỷ lệ vỡ nợ lên tới 99,4%. Rất khó có chuyện một người vay thế chấp hàng trăm nghìn đơn vị tiền lại không có thu nhập, nên nhiều khả năng đây là giá trị bị thiếu nhưng được ghi thành 0. Nhóm chuyển các giá trị này về dạng thiếu và tạo thêm cờ income_zero_flag để không mất đi tín hiệu. Còn chênh lệch lãi suất âm chỉ xuất hiện ở khoản không vỡ nợ, lý do là cột này chỉ có giá trị khi khoản vay không vỡ nợ như sẽ trình bày ở mục 3.3, nên đây không phải lỗi dữ liệu.

3.2. Dữ liệu trùng lặp

Kết quả kiểm tra cho thấy không có dòng nào trùng lặp hoàn toàn và ID không bị lặp, vì vậy nhóm không phải xóa dòng nào. Tuy nhiên dữ liệu lại bị trùng ở cấp độ cột. Ba cột Secured_by, Security_Type và business_or_commercial chứa thông tin đã có ở cột khác như đã nêu trong Bảng 2. Nếu giữ lại, các cột này sẽ gây đa cộng tuyến hoàn hảo trong mô hình tuyến tính nên nhóm quyết định loại bỏ.

3.3. Giá trị thiếu không ngẫu nhiên và hiện tượng rò rỉ dữ liệu

Để quyết định nên xóa hay điền giá trị thiếu, nhóm so sánh tỷ lệ vỡ nợ giữa các dòng bị thiếu và các dòng có dữ liệu ở từng cột. Kết quả được thể hiện trong Hình 3 và Bảng 4.



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 3: Tỷ lệ vỡ nợ khi một cột bị thiếu và khi có dữ liệu

Bảng 4: Bảng chéo giữa việc thiếu lãi suất và Status

rate_of_interest	Không vỡ nợ (0)	Vỡ nợ (1)	Tổng
Có dữ liệu	112.031	200	112.231
Bị thiếu	0	36.439	36.439

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Có thể thấy dữ liệu bị thiếu không hề ngẫu nhiên. Tất cả các khoản thiếu rate_of_interest, Interest_rate_spread, property_value, LTV hoặc age đều là khoản vỡ nợ. Với Upfront_charges và dtir1, tỷ lệ vỡ nợ khi thiếu lần lượt là 92,0% và 67,6%. Ở chiều ngược lại, không có khoản không vỡ nợ nào bị thiếu lãi suất. Nếu chỉ giữ lại các hồ sơ đầy đủ bằng lệnh dropna(), dữ liệu còn 98.187 dòng nhưng không còn khoản vỡ nợ nào, tức là toàn bộ nhóm cần dự báo bị mất. Riêng cột income lại cho kết quả ngược lại, khi thiếu thu nhập thì tỷ lệ vỡ nợ chỉ 13,5%, thấp hơn mức 25,4% của nhóm có dữ liệu.

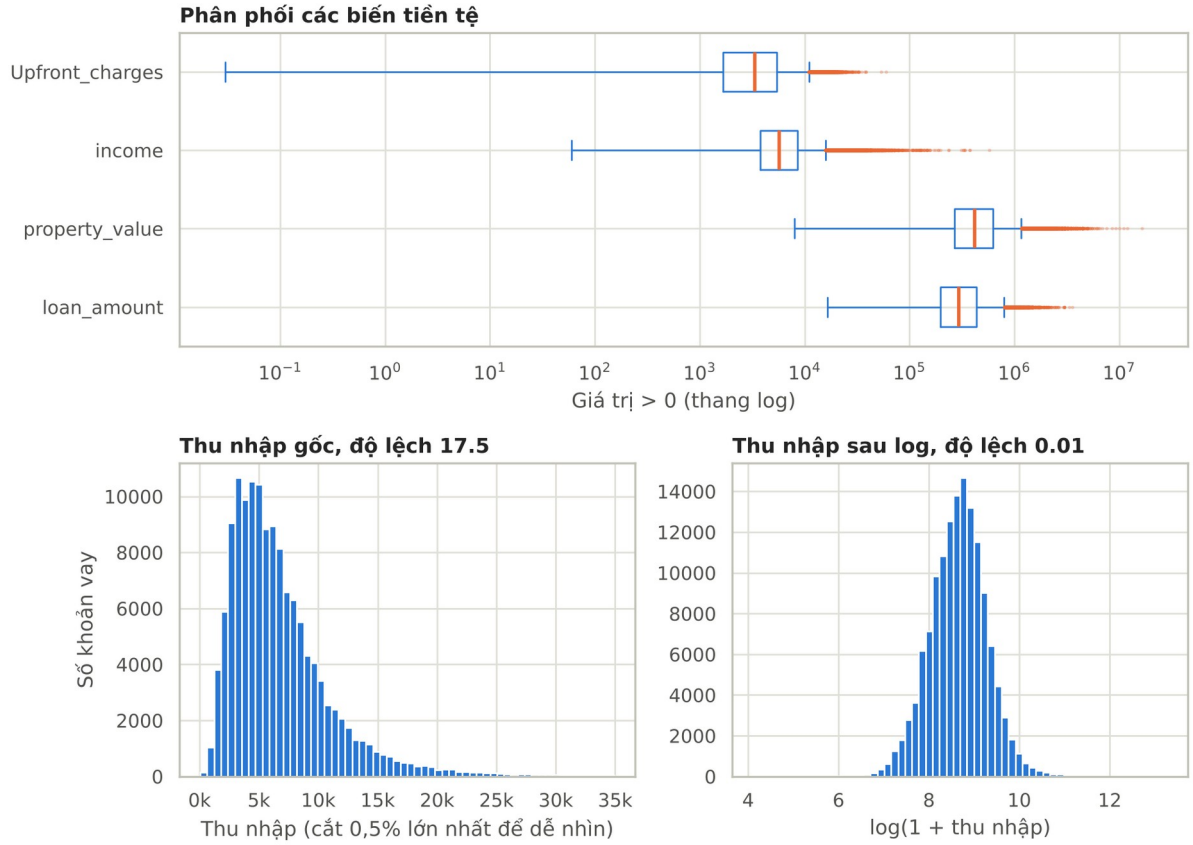
Theo nhóm, cách giải thích hợp lý nhất là hồ sơ của các khoản vỡ nợ được lấy từ một nguồn khác hoặc ở một thời điểm khác, khi các thông tin như lãi suất, phí hay giá trị tài sản không còn được lưu lại. Điều này dẫn tới ba hệ quả cho các bước tiếp theo. Thứ nhất, không được xóa các dòng bị thiếu. Thứ hai, khi điền giá trị thiếu cần giữ lại một cột đánh dấu dòng nào đã bị thiếu. Thứ ba, những thuộc tính này sẽ làm lộ đáp án nếu đưa vào mô hình dự báo, bởi lúc xét duyệt một khoản vay mới ngân hàng không thể biết trước trường nào sẽ bị thiếu. Nhóm kiểm chứng nhận định này bằng mô hình ở mục 4.11.

3.4. Ngoại lệ và độ lệch phân phối

Bảng 5: Phát hiện ngoại lệ bằng phương pháp IQR

Biến	Median	Mean	Độ lệch	Cận trên (Q3 + 1,5 IQR)	Số ngoại lệ	Tỷ lệ
loan_amount	296.500	331.118	1,67	796.500	1.895	1,27%
income	5.760	6.957	17,31	15.720	6.546	4,69%
property_value	418.000	497.893	4,59	1.168.000	5.266	3,94%
LTV	75,14	72,75	120,62	124,75	1.882	1,41%
Upfront_charges	2.596	3.225	1,75	11.159	2.880	2,64%
dtir1	39,0	37,7	âm 0,55	66,0	2.013	1,62%
Credit_Score	699	699,8	0,00	1.101,5	0	0%

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 4: Phân phối các biến tiền tệ và phân phối thu nhập trước, sau khi lấy log

Các biến về tiền đều lệch phải. Thu nhập trung bình là 6.957, cao hơn trung vị 5.760 khoảng 20,8%, và hệ số lệch lên tới 17,3, hay 17,5 nếu bỏ các giá trị 0, do có một số ít người thu nhập rất cao, cao nhất là 578.580. Sau khi lấy log(1+x), hệ số lệch của thu nhập dương chỉ còn 0,01 và phân phối gần như cân đối như ở Hình 4. Với dtir1, phần lớn các điểm bị coi là ngoại lệ theo IQR thực ra là những giá trị DTI thấp hoàn toàn hợp lệ. Nếu xóa mọi dòng có ngoại lệ ở năm biến tiền tệ thì sẽ mất 13.968 dòng, tương đương 9,4% dữ liệu, mà phần lớn trong số đó là những khoản vay và mức thu nhập lớn có thật. Vì vậy nhóm chọn cách cắt ngoại lệ về ngưỡng thay vì xóa.

3.5. Giải trình lựa chọn kỹ thuật

Bảng 6: Các kỹ thuật tiền xử lý và lý do lựa chọn

Vấn đề	Kỹ thuật	Lý do
ID và year	Bỏ cột	ID chỉ là mã định danh, còn year chỉ có một giá trị nên không giúp phân biệt các khoản vay.
Cột trùng thông tin	Bỏ Secured_by, Security_Type và business_or_commercial	Các cột này trùng hoàn toàn với cột khác, giữ lại sẽ gây đa cộng tuyến hoàn hảo.
Nhãn không thống nhất	Đổi south thành South, central thành Central, Sex Not Available thành Không rõ	Nhóm Không rõ có tỷ lệ vỡ nợ 28,6%, khác hẳn các nhóm còn lại nên được giữ thành nhóm riêng thay vì điền mode.
Thu nhập bằng 0	Chuyển thành giá trị thiếu và tạo cờ income_zero_flag	Đây là giá trị không hợp lý nhưng mang tín hiệu rất mạnh với 99,4% vỡ nợ.
Thiếu ở biến số	Điền median và tạo cờ đánh dấu thiếu	Median ít bị ảnh hưởng bởi phân phối lệch và ngoại lệ, trong khi trung bình thu nhập cao hơn median tới 20,8%. Cờ đánh dấu giúp giữ lại thông tin về việc thiếu dữ liệu.
Thiếu ở biến phân loại	Điền mode	Tỷ lệ thiếu không quá 2,25% nên điền mode hầu như không làm thay đổi phân phối.
Ngoại lệ	Cắt về phân vị 1% và 99%	Giữ được đủ 148.670 dòng thay vì mất 9,4% dữ liệu, đồng thời hạn chế ảnh hưởng của những giá trị cực đoan như LTV 7.831%.
10 biến có hai mức	Mã hóa 0 và 1	Cách làm đơn giản và không phát sinh thêm cột.
age và total_units	Mã hóa theo thứ bậc	Giữ được thứ tự tự nhiên của nhóm tuổi và số căn hộ.
6 biến danh nghĩa gồm Gender, loan_type, loan_purpose, occupancy_type, credit_type, Region	Mã hóa One Hot và bỏ cột đầu tiên	Label Encoding sẽ tạo ra thứ tự giả, ví dụ type1 nhỏ hơn type2. Mỗi biến chỉ có 3 hoặc 4 mức nên One Hot không làm số cột tăng quá nhiều, sau mã hóa có 48 cột. Bỏ cột đầu để tránh đa cộng tuyến.
Biến tiền tệ lệch phải	Lấy log(1+x) cho loan_amount, income và property_value	Hệ số lệch của thu nhập giảm từ 1,96 sau khi cắt ngoại lệ xuống còn âm 0,03. Không lấy log Upfront_charges vì cột này có nhiều số 0, lấy log làm hệ số lệch thành âm 1,79.
Thang đo khác nhau	RobustScaler dựa trên median và IQR	MinMaxScaler dễ bị ngoại lệ còn sót lại kéo lệch, StandardScaler dùng trung bình và độ lệch chuẩn nên cũng bị ảnh hưởng.
Rò rỉ trong tiền xử lý	Đưa các bước vào Pipeline và chỉ học tham số trên tập huấn luyện	Tham số dùng để điền và chuẩn hóa không lấy thông tin từ tập kiểm tra.

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Nhóm tạo ra hai bộ dữ liệu cho hai mục đích khác nhau. Bộ df_eda có 148.670 dòng và 30 cột, đã sửa nhãn, bỏ cột thừa và gắn cờ cho giá trị bất hợp lý nhưng vẫn để giá trị thiếu thành một nhóm riêng. Bộ này được dùng cho phân tích ở chương 4. Bộ df_clean có 148.670 dòng và 38 cột, đã điền đủ giá trị và cắt ngoại lệ, dùng để minh họa dữ liệu đầu vào cho mô hình. Lý do nhóm không phân tích trên df_clean được thể hiện ở Bảng 7.

Bảng 7: Tỷ lệ vỡ nợ theo nhóm LTV trước và sau khi điền median

Nhóm LTV	Trước khi điền	Sau khi điền median
Từ 60% trở xuống	13,9%	13,9%
Từ 60% đến 80%	12,9%	33,2%
Từ 80% đến 90%	18,4%	18,4%
Từ 90% đến 100%	19,7%	19,7%
Trên 100%	65,1%	65,1%

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Do median của LTV là 75,14 nên toàn bộ 15.098 khoản thiếu LTV, vốn đều là khoản vỡ nợ, bị dồn vào nhóm từ 60% đến 80%. Tỷ lệ vỡ nợ của nhóm này vì thế tăng từ 12,9% lên 33,2%. Nếu phân tích trên dữ liệu đã điền, nhóm sẽ kết luận sai rằng khoản vay có LTV từ 60% đến 80% rủi ro gấp đôi nhóm từ 80% đến 90%. Như vậy một kỹ thuật điền giá trị phù hợp cho mô hình chưa chắc đã phù hợp cho phân tích mô tả.

CHƯƠNG 4: PHÂN TÍCH, KIỂM ĐỊNH GIẢ THUYẾT VÀ TRỰC QUAN HÓA

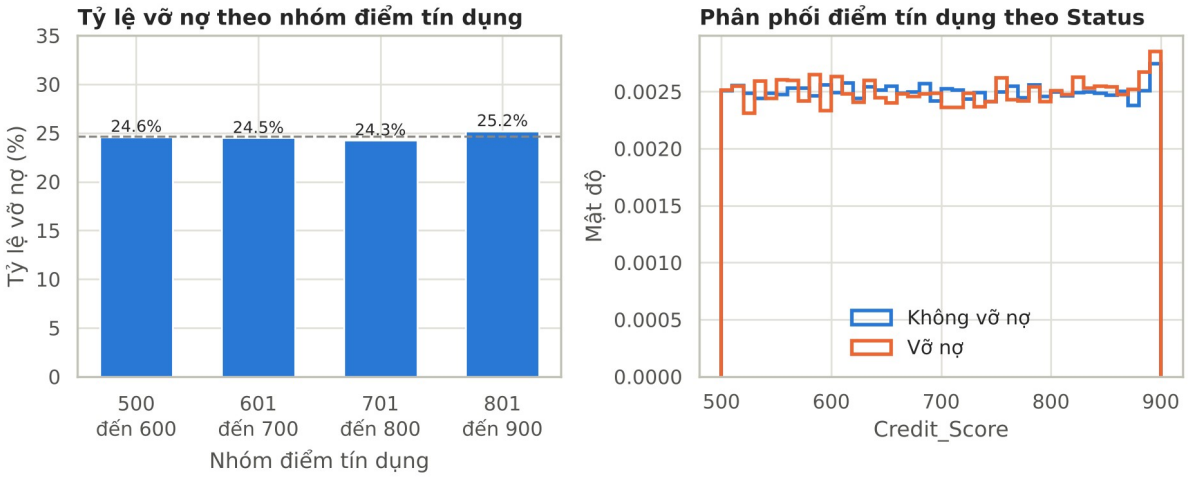
4.1. Giả thuyết và phương pháp kiểm định

Trước khi phân tích, nhóm đặt ra bảy giả thuyết về các yếu tố có thể liên quan đến vỡ nợ.

- H1. Điểm tín dụng càng thấp thì tỷ lệ vỡ nợ càng cao.
- H2. LTV càng cao thì càng dễ vỡ nợ.
- H3. DTI càng cao thì càng dễ vỡ nợ.
- H4. Người vay có thu nhập thấp có tỷ lệ vỡ nợ cao hơn.
- H5. Tỷ lệ vỡ nợ khác nhau giữa các nhóm tuổi.
- H6. Khoản vay có cấu trúc rủi ro như trả gốc âm, trả gộp cuối kỳ, chỉ trả lãi, vay kinh doanh hay vay vượt hạn mức chuẩn có tỷ lệ vỡ nợ cao hơn.
- H7. Tỷ lệ vỡ nợ khác nhau theo đơn vị chấm điểm tín dụng.

Với biến phân loại và biến số đã được chia nhóm, nhóm dùng kiểm định Chi bình phương. Với biến số, nhóm so sánh hai nhóm Status bằng kiểm định Mann Whitney U vì dữ liệu không có phân phối chuẩn. Mức ý nghĩa được chọn là 5%. Do dữ liệu có gần 150.000 quan sát nên gần như mọi khác biệt dù rất nhỏ cũng cho p nhỏ hơn 0,05. Vì vậy nhóm đánh giá thêm độ mạnh của mối liên hệ bằng hệ số Cramér's V, trong đó V dưới 0,1 được xem là không đáng kể, từ 0,1 đến 0,3 là nhỏ, từ 0,3 đến 0,5 là trung bình và từ 0,5 trở lên là lớn theo Cohen (1988). Khi kiểm định một biến, nhóm bỏ các dòng thiếu biến đó để kết quả không bị chi phối bởi hiện tượng thiếu dữ liệu. Trên biểu đồ, nhóm thiếu dữ liệu vẫn được thể hiện bằng cột màu cam để người đọc dễ theo dõi.

4.2. Giả thuyết H1 về điểm tín dụng

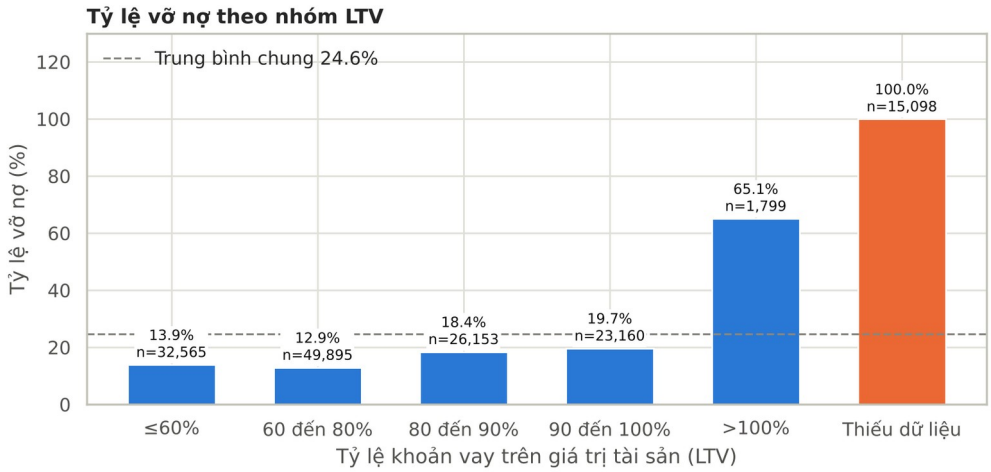


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 5: Tỷ lệ vỡ nợ theo nhóm điểm tín dụng và phân phối điểm tín dụng theo Status

Tỷ lệ vỡ nợ ở bốn nhóm điểm gần như không khác nhau, lần lượt là 24,6%, 24,5%, 24,3% và 25,2%. Kiểm định Chi bình phương cho p bằng 0,024 nhưng Cramér's V chỉ là 0,008, gần như bằng 0. Kiểm định Mann Whitney U cho p bằng 0,124 và trung vị điểm tín dụng của hai nhóm là 700 và 699. Vì vậy nhóm bác bỏ giả thuyết H1 xét về ý nghĩa thực tiễn. Biểu đồ bên phải còn cho thấy điểm tín dụng phân bố khá đều từ 500 đến 900, mỗi khoảng 50 điểm có từ 18.251 đến 18.896 khoản vay. Điểm tín dụng thực tế thường không phân bố đều như vậy, nên nhiều khả năng biến này đã được làm ẩn danh hoặc tạo ngẫu nhiên khi tác giả công bố dữ liệu. Từ đây nhóm rút ra rằng trước khi dùng một biến tưởng như chắc chắn quan trọng thì vẫn cần kiểm tra phân phối của nó.

4.3. Giả thuyết H2 về tỷ lệ khoản vay trên giá trị tài sản

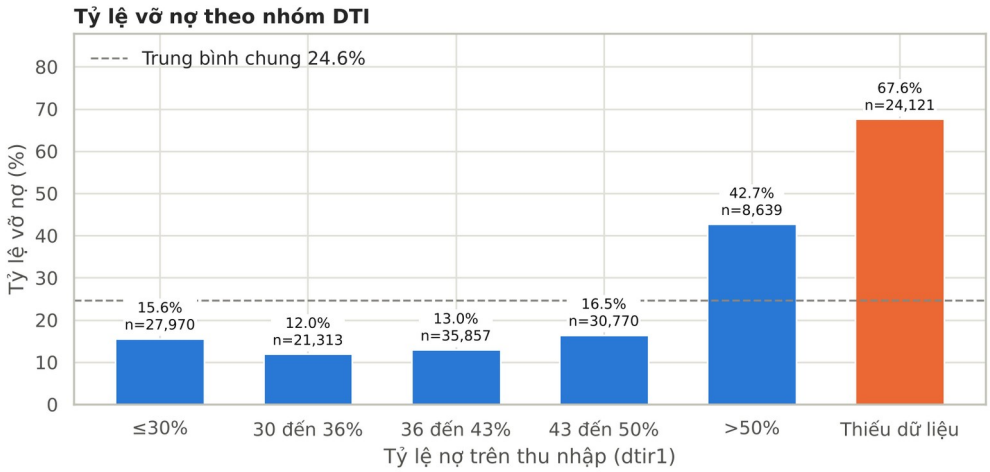


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 6: Tỷ lệ vỡ nợ theo nhóm LTV

Mối quan hệ giữa LTV và vỡ nợ không tăng đều mà thay đổi theo ngưỡng. Khi LTV dưới 80%, tỷ lệ vỡ nợ khá ổn định ở mức khoảng 13%. Nhóm có LTV từ 80% đến 100% tăng lên khoảng 18% đến 20%. Nhưng khi LTV vượt 100%, tỷ lệ vỡ nợ tăng vọt lên 65,1%, cao gấp khoảng 5 lần nhóm từ 60% đến 80%. Kiểm định Chi bình phương có p nhỏ hơn 0,001 với Cramér's V bằng 0,173. Hệ số Spearman chỉ là 0,090 vì phần lớn khoản vay nằm ở vùng LTV thấp, nơi tỷ lệ vỡ nợ gần như không đổi. Có thể hiểu khi khoản vay lớn hơn giá trị tài sản, người vay dù bán tài sản cũng không đủ trả nợ nên động lực tiếp tục trả nợ giảm đi. Giả thuyết H2 được chấp nhận và mức 100% là ngưỡng rõ ràng nhất.

4.4. Giả thuyết H3 về tỷ lệ nợ trên thu nhập

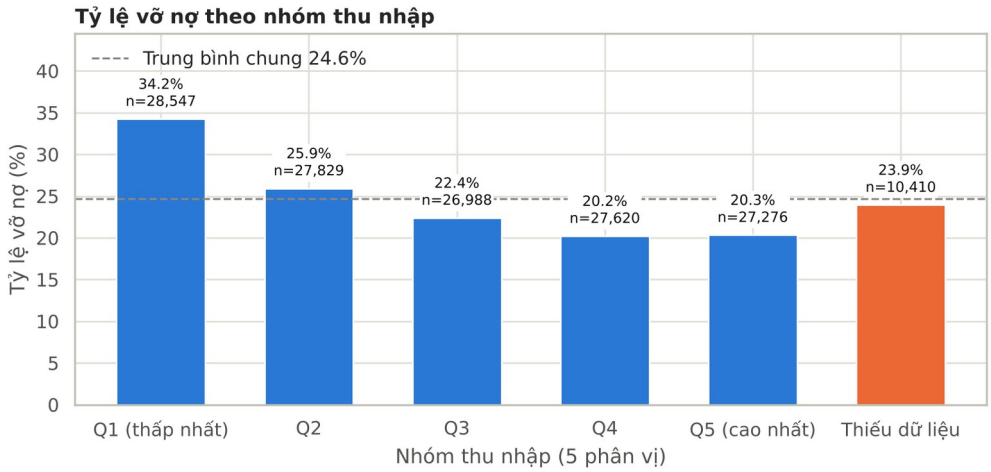


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 7: Tỷ lệ vỡ nợ theo nhóm DTI

Nhóm có DTI trên 50% có tỷ lệ vỡ nợ 42,7%, gấp 3,6 lần nhóm từ 30% đến 36% với 12,0%. Cramér's V bằng 0,201, cao nhất trong các biến số được kiểm định. Nhóm cũng nhận thấy những người có DTI thấp nhất, từ 30% trở xuống, lại vỡ nợ nhiều hơn nhóm từ 30% đến 43%, cụ thể là 15,6% so với khoảng 12% đến 13%. Như vậy DTI thấp chưa chắc đã an toàn. Một cách giải thích có thể là đây là những khoản vay nhỏ của người có thu nhập kê khai cao nhưng không ổn định, tuy nhiên cần thêm dữ liệu để kiểm chứng. Nhóm thiếu DTI có tỷ lệ vỡ nợ 67,6%. Giả thuyết H3 được chấp nhận với ngưỡng 50%.

4.5. Giả thuyết H4 về thu nhập

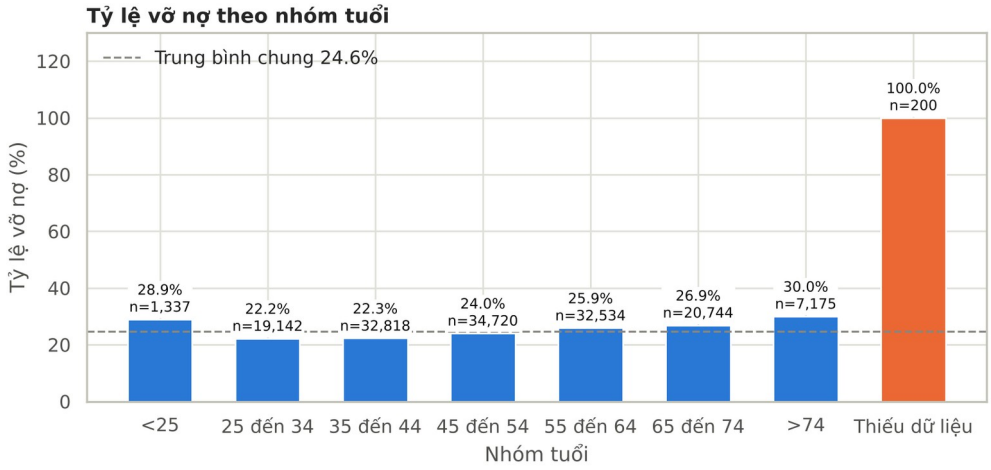


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 8: Tỷ lệ vỡ nợ theo năm nhóm thu nhập

Tỷ lệ vỡ nợ giảm dần từ 34,2% ở nhóm thu nhập thấp nhất, tức thu nhập không quá 3.420, xuống còn khoảng 20,2% đến 20,3% ở hai nhóm cao nhất. Cramér's V bằng 0,123 và kiểm định Mann Whitney U có p nhỏ hơn 0,001. Trung vị thu nhập của người vỡ nợ là 5.040, thấp hơn mức 6.000 của người không vỡ nợ. Tuy nhiên từ nhóm Q4, tức thu nhập trên khoảng 6.720, tỷ lệ vỡ nợ gần như không giảm thêm. Điều này cho thấy thu nhập chủ yếu có ý nghĩa khi dùng để sàng lọc những người thu nhập thấp. Bên cạnh đó, 1.260 hồ sơ có thu nhập bằng 0 có tỷ lệ vỡ nợ 99,4%. Giả thuyết H4 được chấp nhận.

4.6. Giả thuyết H5 về nhóm tuổi

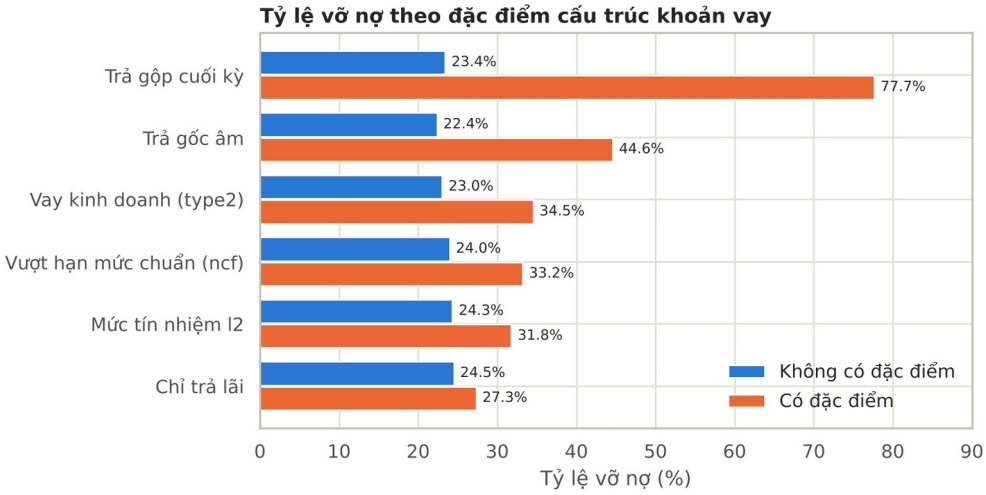


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 9: Tỷ lệ vỡ nợ theo nhóm tuổi

Tỷ lệ vỡ nợ thấp nhất ở nhóm từ 25 đến 44 tuổi với khoảng 22,2%, sau đó tăng dần và lên tới 30,0% ở nhóm trên 74 tuổi. Nhóm dưới 25 tuổi cũng có tỷ lệ khá cao là 28,9%, dù nhóm này chỉ có 1.337 khoản vay. Khác biệt giữa các nhóm tuổi có ý nghĩa thống kê với p nhỏ hơn 0,001 nhưng Cramér's V chỉ bằng 0,050, tức mức độ ảnh hưởng không đáng kể. Giả thuyết H5 được chấp nhận về mặt thống kê nhưng tác động nhỏ. Ngoài ra tuổi là thông tin nhạy cảm, nếu dùng trong xét duyệt cho vay thì cần cân nhắc tới tính công bằng.

4.7. Giả thuyết H6 về cấu trúc khoản vay

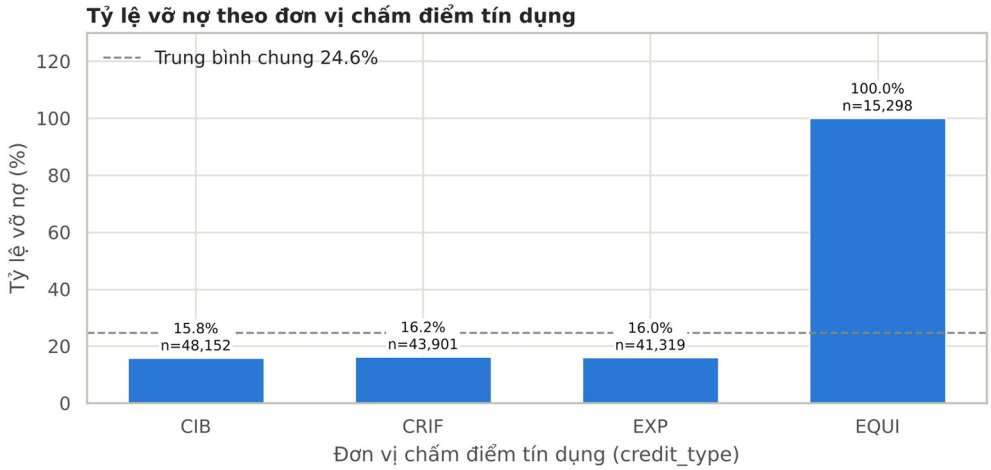


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 10: Tỷ lệ vỡ nợ khi có và không có từng đặc điểm cấu trúc khoản vay

Hai hình thức trả nợ có rủi ro cao nhất là trả gộp cuối kỳ và trả gốc âm. Khoản vay trả gộp cuối kỳ có tỷ lệ vỡ nợ 77,7%, gấp 3,3 lần mức 23,4% của các khoản còn lại, với Cramér's V bằng 0,188. Khoản vay trả gốc âm có tỷ lệ 44,6%, gấp đôi mức 22,4%, với Cramér's V bằng 0,156. Với hình thức trả gộp, người vay phải chuẩn bị một khoản tiền lớn vào cuối kỳ hoặc phải vay mới để trả nợ cũ. Với hình thức trả gốc âm, số tiền trả hàng kỳ không đủ bù lãi nên dư nợ tăng dần, nghĩa là LTV cũng tăng theo thời gian, cơ chế này giống với giả thuyết H2. Các khoản vay kinh doanh, vay vượt hạn mức chuẩn và khoản có mức tín nhiệm l2 cũng có tỷ lệ vỡ nợ cao hơn mức chung, lần lượt là 34,5%, 33,2% và 31,8%, nhưng mức độ ảnh hưởng yếu hơn. Riêng hình thức chỉ trả lãi chỉ cao hơn 2,8 điểm phần trăm với V bằng 0,014 nên gần như không có ý nghĩa thực tiễn. Giả thuyết H6 được chấp nhận, trừ trường hợp chỉ trả lãi.

4.8. Giả thuyết H7 về đơn vị chấm điểm tín dụng

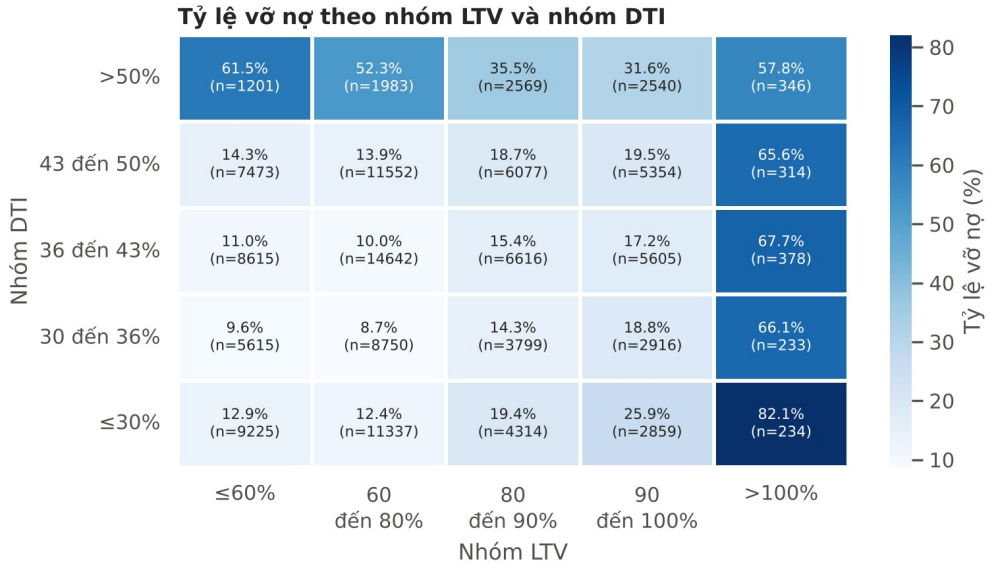


Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 11: Tỷ lệ vỡ nợ theo đơn vị chấm điểm tín dụng

Ba đơn vị CIB, CRIF và EXP có tỷ lệ vỡ nợ gần như nhau, từ 15,8% đến 16,2%. Trong khi đó, 99,99% trong số 15.298 hồ sơ do EQUI chấm điểm bị vỡ nợ, Cramér's V bằng 0,592 và là mức cao nhất trong các kiểm định. Tuy vậy, nhóm không cho rằng EQUI chấm điểm kém. Có tới 98,7% hồ sơ của EQUI cũng bị thiếu lãi suất, tức là cùng hiện tượng ghi nhận dữ liệu đã nêu ở mục 3.3. Nhiều khả năng các khoản vỡ nợ được lấy từ một nguồn có gắn nhãn EQUI. Với người đồng vay, nhóm được EXP chấm điểm có tỷ lệ vỡ nợ 30,9%, cao hơn mức 18,4% của nhóm được CIB chấm điểm, V bằng 0,144. Giả thuyết H7 được chấp nhận về mặt thống kê, nhưng chưa đủ cơ sở để đánh giá chất lượng của từng đơn vị chấm điểm, và credit_type cần được loại khỏi mô hình dự báo.

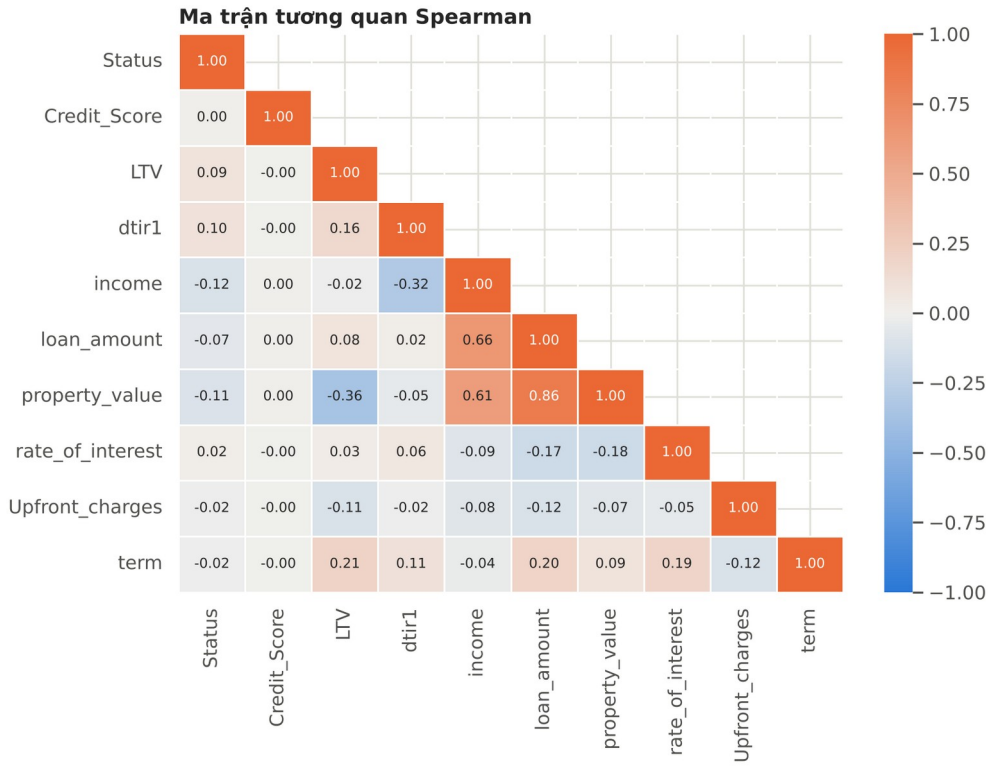
4.9. Kết hợp LTV với DTI và tương quan giữa các biến số



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 12: Tỷ lệ vỡ nợ theo nhóm LTV và nhóm DTI

Vùng an toàn nhất là các khoản có LTV từ 60% đến 80% và DTI từ 30% đến 36%, với tỷ lệ vỡ nợ chỉ 8,7%. Khi LTV vượt 100% thì ở mức DTI nào tỷ lệ vỡ nợ cũng rất cao, từ 57,8% đến 82,1%. Điều nhóm không ngờ tới là DTI trên 50% vẫn rất rủi ro kể cả khi tài sản bảo đảm tốt. Các khoản có LTV không quá 60% nhưng DTI trên 50% có tỷ lệ vỡ nợ 61,5% với 1.201 khoản, cao hơn nhiều so với các khoản có LTV từ 90% đến 100% và DTI trên 50% với 31,6%. Hai yếu tố này không cộng dồn theo kiểu tuyến tính, nên nếu chỉ dùng một điểm số tuyến tính đơn giản thì có thể đánh giá thấp rủi ro. Vì vậy chính sách cho vay nên đặt ngưỡng riêng cho từng chỉ số.



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 13: Ma trận tương quan Spearman giữa các biến số

Hệ số tương quan giữa Status và các biến số đều nhỏ, giá trị tuyệt đối không quá 0,12. Cụ thể thu nhập là âm 0,116, giá trị tài sản là âm 0,108, DTI là 0,096, LTV là 0,090 và điểm tín dụng chỉ 0,004. Kết quả này không mâu thuẫn với các mục 4.3 đến 4.5, bởi quan hệ theo ngưỡng chỉ thấy rõ khi chia nhóm, còn hệ số tương quan phản ánh xu hướng chung trên toàn bộ khoảng giá trị. Giữa các biến giải thích có một số cặp tương quan mạnh như số tiền vay với giá trị tài sản là 0,86, số tiền vay với thu nhập là 0,66 và giá trị tài sản với thu nhập là 0,61. Đây là dấu hiệu đa cộng tuyến cần lưu ý khi dùng hồi quy Logistic. Biến Interest_rate_spread không được đưa vào ma trận vì cột này chỉ có giá trị khi Status bằng 0.

4.10. Tổng hợp kết quả kiểm định

Bảng 8: Kết quả kiểm định các giả thuyết

GT	Biến	Kiểm định	Thống kê	p value	Cramér's V	Kết luận
H1	Nhóm điểm tín dụng	χ^2	9,5	0,024	0,008	Bác bỏ vì không đáng kể
H1	Credit_Score	Mann Whitney U		0,124		Không khác biệt
H2	Nhóm LTV	χ^2	4.000,8	< 0,001	0,173	Chấp nhận
H3	Nhóm DTI	χ^2	5.014,0	< 0,001	0,201	Chấp nhận
H4	Nhóm thu nhập	χ^2	2.075,6	< 0,001	0,123	Chấp nhận
H5	Nhóm tuổi	χ^2	374,5	< 0,001	0,050	Chấp nhận, tác động yếu
H6	Trả gộp cuối kỳ	χ^2	5.237,8	< 0,001	0,188	Chấp nhận
H6	Trả gốc âm	χ^2	3.610,2	< 0,001	0,156	Chấp nhận
H6	Vay kinh doanh	χ^2	1.272,8	< 0,001	0,093	Chấp nhận, tác động yếu
H6	Vượt hạn mức chuẩn	χ^2	427,4	< 0,001	0,054	Chấp nhận, tác động yếu
H6	Mức tín nhiệm l2	χ^2	180,4	< 0,001	0,035	Chấp nhận, tác động yếu
H6	Chỉ trả lãi	χ^2	28,5	< 0,001	0,014	Không đáng kể
H7	credit_type	χ^2	52.135,3	< 0,001	0,592	Có liên hệ nhưng do rò rỉ dữ liệu
H7	Đơn vị chấm điểm người đồng vay	χ^2	3.092,4	< 0,001	0,144	Chấp nhận

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

4.11. Kiểm chứng bằng mô hình học máy

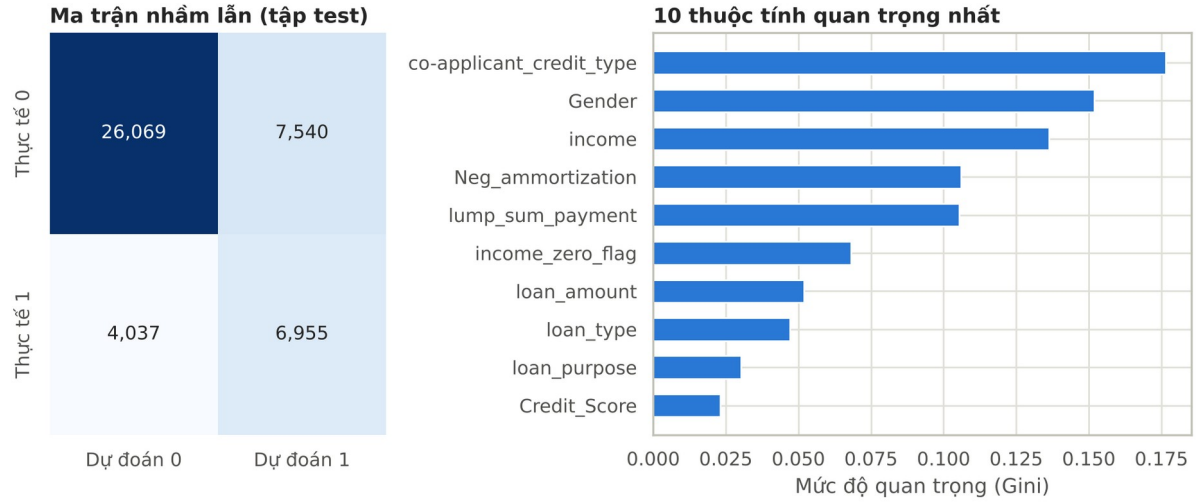
Để kiểm chứng nhận định về rò rỉ dữ liệu ở mục 3.3 và xem dữ liệu thực sự dự báo được tới đâu, nhóm huấn luyện hai mô hình là hồi quy Logistic và Random Forest với 200 cây, độ sâu tối đa 12 và có cân bằng trọng số giữa hai lớp. Dữ liệu được chia 70% để huấn luyện và 30% để kiểm tra, tương đương 44.601 khoản, có phân tầng theo Status. Nhóm thử hai kịch bản. Kịch bản A dùng toàn bộ thuộc tính. Kịch bản B bỏ đi 10 thuộc tính mà việc thiếu dữ liệu gần như quyết định Status, gồm rate_of_interest,

Interest_rate_spread, Upfront_charges, property_value, LTV, dtir1, credit_type, age, submission_of_application và construction_type.

Bảng 9: Kết quả mô hình trên tập kiểm tra

Kịch bản	Mô hình	AUC	Accuracy	Precision	Recall	F1
A. Toàn bộ thuộc tính	Logistic Regression	1,000	1,000	1,000	1,000	1,000
A. Toàn bộ thuộc tính	Random Forest	1,000	1,000	1,000	1,000	1,000
B. Bỏ thuộc tính rò rỉ	Logistic Regression	0,742	0,710	0,439	0,630	0,518
B. Bỏ thuộc tính rò rỉ	Random Forest	0,771	0,740	0,480	0,633	0,546

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)



Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Hình 14: Ma trận nhầm lẫn và mức độ quan trọng của thuộc tính trong mô hình Random Forest ở kịch bản B

Ở kịch bản A, cả hai mô hình đều đạt điểm tuyệt đối. Đạt điểm tuyệt đối như vậy là dấu hiệu của rò rỉ dữ liệu, vì mô hình chỉ cần học quy tắc thiếu lãi suất thì vỡ nợ, một quy tắc không thể dùng khi xét duyệt khoản vay mới. Sau khi bỏ các thuộc tính rò rỉ, Random Forest đạt AUC 0,771 và F1 0,546, tốt hơn hồi quy Logistic với AUC 0,742. Điều này phù hợp với các quan hệ theo ngưỡng đã thấy ở những mục trước, vì mô hình dạng cây xử lý tốt các quan hệ phi tuyến.

Theo ma trận nhầm lẫn, mô hình phát hiện được 6.955 trên 10.992 khoản vỡ nợ, tương ứng Recall 63,3%. Mô hình bỏ sót 4.037 khoản và cảnh báo nhầm 7.540 trên 33.609 khoản không vỡ nợ. Các thuộc tính quan trọng nhất gồm đơn vị chấm điểm của

người đồng vay với 0,177, giới tính 0,152, thu nhập 0,136, trả gốc âm 0,106 và trả gộp cuối kỳ 0,105. Kết quả này một lần nữa cho thấy vai trò của thu nhập và cấu trúc khoản vay như ở giả thuyết H4 và H6. Giới tính có mức quan trọng cao chủ yếu do nhóm Không rõ có tỷ lệ vỡ nợ 28,6% còn nhóm vay chung chỉ 19,2%. Việc dùng giới tính để quyết định cho vay có nguy cơ phân biệt đối xử, nên khi áp dụng thực tế nhóm đề xuất thay bằng một biến trung lập hơn như có hay không có người đồng vay.

CHƯƠNG 5: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

5.1. Các phát hiện nổi bật

1. Chất lượng dữ liệu là vấn đề lớn nhất. Việc thiếu dữ liệu gắn gần như tuyệt đối với vỡ nợ khiến mọi mô hình dùng nguyên dữ liệu đều cho độ chính xác 100% không có thật.
2. Đòn bẩy tài chính là nhóm yếu tố rủi ro rõ nhất. Khoản vay có LTV trên 100% vỡ nợ 65,1% và khoản vay có DTI trên 50% vỡ nợ 42,7%, cả hai đều thay đổi theo ngưỡng.
3. Cách thức trả nợ ảnh hưởng mạnh hơn các đặc điểm nhân khẩu học. Trả gộp cuối kỳ và trả gốc âm có tỷ lệ vỡ nợ 77,7% và 44,6%, trong khi tác động của tuổi rất nhỏ với V bằng 0,050.
4. Thu nhập chủ yếu có ý nghĩa ở nhóm thấp. Nhóm thu nhập thấp nhất vỡ nợ 34,2% so với khoảng 20% ở nhóm cao, và từ mức khoảng 6.720 trở lên thì thu nhập gần như không còn tác động.
5. Điểm tín dụng trong bộ dữ liệu không có giá trị dự báo và có dấu hiệu đã bị làm ẩn danh hoặc tạo ngẫu nhiên.

5.2. Đánh giá tác động của quy tắc sàng lọc

Nhóm thử áp dụng hai quy tắc sàng lọc trên 124.547 hồ sơ có đủ thông tin LTV và DTI. Tỷ lệ vỡ nợ chung của nhóm hồ sơ này là 16,3%.

Bảng 10: Mô phỏng tác động của quy tắc sàng lọc

Quy tắc	Hồ sơ bị gắn cờ	Vỡ nợ trong nhóm gắn cờ	Vỡ nợ nhóm còn lại	Tỷ lệ khoản vỡ nợ bắt được
Quy tắc 1: LTV trên 100% hoặc DTI trên 50%	7,9%	45,9%	13,8%	22,1%
Quy tắc 2: Quy tắc 1 cộng thêm trả gộp cuối kỳ hoặc trả gốc âm	18,0%	38,9%	11,4%	42,9%

Nguồn: Nhóm tác giả tính toán từ Loan Default Dataset (Kaggle)

Chỉ với bốn điều kiện có thể kiểm tra ngay trên hồ sơ, quy tắc 2 đã gom được 42,9% số khoản vỡ nợ vào 18% hồ sơ cần thẩm định kỹ. Tỷ lệ vỡ nợ của 82% hồ sơ còn lại giảm từ 16,3% xuống 11,4%. Cách làm này đơn giản, dễ giải thích với khách hàng cũng như cơ quan quản lý. Mô hình Random Forest ở mục 4.11 có thể dùng thêm như một công cụ chấm điểm thứ hai.

5.3. Khuyến nghị

1. Về LTV, ngân hàng nên đặt mức trần 90% cho hồ sơ thông thường. Khoản vay có LTV trên 100% chỉ nên chấp nhận khi có thêm tài sản bảo đảm hoặc bảo hiểm khoản vay.
2. Về DTI, nên đặt mức trần 50% và thẩm định kỹ hơn với hồ sơ có DTI từ 43% đến 50%. Mức trần này cần áp dụng cả khi LTV thấp, vì tài sản bảo đảm tốt không bù được khả năng trả nợ yếu, như nhóm có LTV không quá 60% và DTI trên 50% vẫn vỡ nợ 61,5%.
3. Về thiết kế sản phẩm, nên hạn chế hoặc nâng điều kiện đối với khoản vay trả gộp cuối kỳ và trả gốc âm, chẳng hạn yêu cầu kế hoạch tài chính cho khoản trả cuối kỳ hoặc giới hạn mức tăng dư nợ. Khoản vay kinh doanh và khoản vay vượt hạn mức chuẩn nên được định giá cao hơn tương ứng với rủi ro.
4. Về thu nhập, không nên phê duyệt tự động các hồ sơ có thu nhập bằng 0 hoặc không xác minh được, đồng thời ưu tiên thẩm định nhóm có thu nhập thấp nhất.
5. Về quản lý dữ liệu, ngân hàng cần ghi nhận đầy đủ lãi suất, phí, giá trị tài sản và DTI của mọi khoản vay tại thời điểm giải ngân, đồng thời lưu riêng bản dữ liệu tại thời điểm xét duyệt, tách khỏi dữ liệu theo dõi sau giải ngân. Đây là điều kiện để xây dựng được mô hình dự báo không bị rò rỉ.
6. Về điểm tín dụng, cần kiểm tra lại nguồn và cách tính Credit_Score trước khi dùng trong quyết định cho vay, vì biến này hiện không phân biệt được rủi ro.
7. Về tính công bằng, không nên dùng giới tính và cần thận trọng khi dùng tuổi trong quyết định cho vay. Ngưỡng phân loại của mô hình cũng nên được điều chỉnh dựa trên chi phí thực tế của việc bỏ sót một khoản vỡ nợ so với việc từ chối nhầm một khách hàng tốt.

5.4. Hạn chế của dữ liệu và hướng mở rộng

Bộ dữ liệu có một số hạn chế. Dữ liệu chỉ thuộc năm 2019 và không rõ quốc gia, đơn vị tiền tệ cũng như thu nhập được tính theo tháng hay theo năm, nên khó so sánh với thực tế tại Việt Nam. Bộ dữ liệu không có từ điển chính thức, nhiều mã như type1 đến type3, p1 đến p4 hay l1, l2 chưa rõ ý nghĩa nên phần diễn giải của nhóm chỉ là giả định. Hiện tượng thiếu dữ liệu không ngẫu nhiên khiến tỷ lệ vỡ nợ 24,6% có thể không phản ánh đúng danh mục cho vay thực tế và làm giảm số thuộc tính dùng được cho dự báo. Biến Credit_Score có dấu hiệu đã bị làm ẩn danh hoặc tạo ngẫu nhiên. Ngoài ra dữ liệu không có các biến thời gian như ngày giải ngân hay thời điểm vỡ nợ, cũng không có các biến vĩ mô như lãi suất thị trường, giá nhà hay tỷ lệ thất nghiệp. Các kiểm định trong báo cáo chỉ cho thấy mối liên hệ chứ chưa chứng minh được quan hệ nhân quả.

Trong thời gian tới, nghiên cứu có thể được mở rộng theo một số hướng. Thứ nhất là thu thập dữ liệu của nhiều năm kèm theo các biến vĩ mô để phân tích theo chu kỳ kinh tế. Thứ hai là xác nhận lại từ điển dữ liệu với nguồn và bổ sung các trường bị thiếu ở khoản vỡ nợ. Thứ ba là thử các mô hình như Gradient Boosting, tối ưu ngưỡng phân loại theo chi phí, giải thích mô hình bằng SHAP và xây dựng thẻ điểm tín dụng bằng WOE và IV. Cuối cùng là kiểm tra tính công bằng của mô hình theo giới tính, tuổi và dùng phân tích sống còn để dự báo thời điểm vỡ nợ.

KẾT LUẬN

Báo cáo đã thực hiện đầy đủ bốn giai đoạn của quy trình khoa học dữ liệu trên bộ Loan Default Dataset. Kết quả quan trọng nhất mà nhóm thu được là phát hiện dữ liệu thiếu không ngẫu nhiên, khiến độ chính xác 100% của mô hình trở nên vô nghĩa, và từ đó xác định được những yếu tố rủi ro vẫn đứng vững sau khi loại bỏ rò rỉ. Các yếu tố đó gồm LTV trên 100%, DTI trên 50%, hình thức trả gộp cuối kỳ, trả gốc âm và thu nhập thấp. Những khuyến nghị của nhóm tập trung vào ngưỡng đòn bẩy, thiết kế sản phẩm và quản lý dữ liệu. Đây là các biện pháp có thể triển khai ngay, dễ giải thích và có tác động đo được, khi chỉ một quy tắc sàng lọc đơn giản đã gom được 42,9% số khoản vỡ nợ vào 18% hồ sơ.

TÀI LIỆU THAM KHẢO

1. Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
2. Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357 to 362.
3. Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, *9*(3), 90 to 95.
4. Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), 1 to 21.
5. McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.
6. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825 to 2830.
7. Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, *17*(3), 261 to 272.
8. Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, *6*(60), 3021.
9. Yasser H. (n.d.). *Loan default dataset* [Data set]. Kaggle. https://www.kaggle.com/datasets/yasserh/loan-default-dataset

PHỤ LỤC

Phụ lục 1: Cấu trúc repository GitHub và cách chạy lại

Đường dẫn repository: https://github.com/hunganh33333/loan-default-midterm2

File trong repository	Nội dung
Loan_Default_Analysis.ipynb	Notebook Colab chạy được từ đầu đến cuối bằng Run all, đã kèm sẵn kết quả và biểu đồ
Bao_cao_Giua_ky_2_Nhom_2.pdf	Báo cáo này
README.md	Mô tả dự án, thành viên và hướng dẫn chạy

Để chạy lại, mở notebook trên Google Colab bằng cách chọn File, Open notebook, sau đó chọn thẻ GitHub và dán đường dẫn repository. Tiếp theo chọn Runtime rồi chọn Run all. Notebook tự tải dữ liệu từ Kaggle bằng thư viện kagglehub mà không cần đăng nhập và tự lưu 14 biểu đồ vào thư mục figures. Nếu không tải được dữ liệu, có thể kéo file Loan_Default.csv vào thư mục bên trái của Colab rồi chạy lại.